



模型平台 v1技术需求文档

1. 背景与目标

- 1.1 现状
- 1.2 投产前的核心问题
- 1.3 目标
- 1.4 说明

2. 需求一：日志与监控体系

- 2.1 请求访问日志
- 2.2 Prometheus 指标
 - 2.2.1 请求指标
 - 2.2.2 Token/用量指标
 - 2.2.3 系统健康指标
- 2.3 Grafana 仪表盘（需运维配...
- 2.4 告警规则（需运维配置）
- 2.5 控制台日志查询 API

3. 需求二：分级调用策略体系

- 3.1 策略模型设计
 - 3.1.1 三级优先级
 - 3.1.2 每个 AppKey × 每个模...
 - 3.1.3 全局模型并发配置
 - 3.1.4 计费逻辑
- 3.2 策略执行流程
- 3.3 策略管理 API
 - 3.3.1 AppKey 策略配置
 - 3.3.2 模型容量配置
 - 3.3.3 实时状态查询
- 3.4 429 响应格式规范
- 3.4 初始化建议

模型平台 v1技术需求文档

Modified Jul 13, 2026

1. 背景与目标

1.1 现状

模型平台访问路径：

<https://model.dev.beemwk.com:8805/login> (<https://10.224.10.224:8805/login>)
<https://model-platform.beemchat.com/>

管理员账户：

admin@beem.com， 密码123456

测试账号：

test@beem.com 111111

代码仓：

<https://gitlab.beemwk.com/beem-ai/model-platform>（需要后台后，管理员才能加入进来）

当前模型平台处于 Demo 阶段，基本具备：

- 多模型代理转发（通过 LiteLLM）
- AppKey 管理（创建/撤销，含预算上限和月度 Token 限额）
- 用量计费统计（按 Token/音频时长/字符数计费）
- 组织/成员/配额管理
- 管理后台和审计日志（管理动作级别）

1.2 投产前的核心问题

<<

模型平台 v1 技术需求文档

1. 背景与目标

1.1 现状

1.2 投产前的核心问题

1.3 目标

1.4 说明

2. 需求一：日志与监控体系

2.1 请求访问日志

2.2 Prometheus 指标

2.2.1 请求指标

2.2.2 Token/用量指标

2.2.3 系统健康指标

2.3 Grafana 仪表盘（需运维配...

2.4 告警规则（需运维配置）

2.5 控制台日志查询 API

3. 需求二：分级调用策略体系

3.1 策略模型设计

3.1.1 三级优先级

3.1.2 每个 AppKey × 每个模...

3.1.3 全局模型并发配置

3.1.4 计费逻辑

3.2 策略执行流程

3.3 策略管理 API

3.3.1 AppKey 策略配置

3.3.2 模型容量配置

3.3.3 实时状态查询

3.4 429 响应格式规范

3.4 初始化建议

<<

模型平台 v1 技术需求文档

1. 背景与目标

1.1 现状

1.2 投产前的核心问题

1.3 目标

1.4 说明

2. 需求一：日志与监控体系

2.1 请求访问日志

2.2 Prometheus 指标

2.2.1 请求指标

2.2.2 Token/用量指标

2.2.3 系统健康指标

2.3 Grafana 仪表盘（需运维配...

2.4 告警规则（需运维配置）

2.5 控制台日志查询 API

3. 需求二：分级调用策略体系

3.1 策略模型设计

3.1.1 三级优先级

3.1.2 每个 AppKey × 每个模...

3.1.3 全局模型并发配置

3.1.4 计费逻辑

3.2 策略执行流程

3.3 策略管理 API

3.3.1 AppKey 策略配置

3.3.2 模型容量配置

3.3.3 实时状态查询

3.4 429 响应格式规范

3.4 初始化建议

<<

模型平台 v1 技术需求文档

1. 背景与目标

1.1 现状

1.2 投产前的核心问题

1.3 目标

1.4 说明

2. 需求一：日志与监控体系

2.1 请求访问日志

2.2 Prometheus 指标

2.2.1 请求指标

2.2.2 Token/用量指标

2.2.3 系统健康指标

2.3 Grafana 仪表盘（需运维配...

2.4 告警规则（需运维配置）

2.5 控制台日志查询 API

3. 需求二：分级调用策略体系

3.1 策略模型设计

3.1.1 三级优先级

3.1.2 每个 AppKey × 每个模...

3.1.3 全局模型并发配置

3.1.4 计费逻辑

3.2 策略执行流程

3.3 策略管理 API

3.3.1 AppKey 策略配置

3.3.2 模型容量配置

3.3.3 实时状态查询

3.4 429 响应格式规范

3.4 初始化建议

<<

模型平台 v1 技术需求文档

1. 背景与目标

1.1 现状

1.2 投产前的核心问题

1.3 目标

1.4 说明

2. 需求一：日志与监控体系

2.1 请求访问日志

2.2 Prometheus 指标

2.2.1 请求指标

2.2.2 Token/用量指标

2.2.3 系统健康指标

2.3 Grafana 仪表盘（需运维配...

2.4 告警规则（需运维配置）

2.5 控制台日志查询 API

3. 需求二：分级调用策略体系

3.1 策略模型设计

3.1.1 三级优先级

3.1.2 每个 AppKey × 每个模...

3.1.3 全局模型并发配置

3.1.4 计费逻辑

3.2 策略执行流程

3.3 策略管理 API

3.3.1 AppKey 策略配置

3.3.2 模型容量配置

3.3.3 实时状态查询

3.4 429 响应格式规范

3.4 初始化建议

<<

模型平台 v1 技术需求文档

1. 背景与目标

1.1 现状

1.2 投产前的核心问题

1.3 目标

1.4 说明

2. 需求一：日志与监控体系

2.1 请求访问日志

2.2 Prometheus 指标

2.2.1 请求指标

2.2.2 Token/用量指标

2.2.3 系统健康指标

2.3 Grafana 仪表盘（需运维配...

2.4 告警规则（需运维配置）

2.5 控制台日志查询 API

3. 需求二：分级调用策略体系

3.1 策略模型设计

3.1.1 三级优先级

3.1.2 每个 AppKey × 每个模...

3.1.3 全局模型并发配置

3.1.4 计费逻辑

3.2 策略执行流程

3.3 策略管理 API

3.3.1 AppKey 策略配置

3.3.2 模型容量配置

3.3.3 实时状态查询

3.4 429 响应格式规范

3.4 初始化建议

<<

模型平台 v1 技术需求文档

1. 背景与目标

1.1 现状

1.2 投产前的核心问题

1.3 目标

1.4 说明

2. 需求一：日志与监控体系

2.1 请求访问日志

2.2 Prometheus 指标

2.2.1 请求指标

2.2.2 Token/用量指标

2.2.3 系统健康指标

2.3 Grafana 仪表盘（需运维配...

2.4 告警规则（需运维配置）

2.5 控制台日志查询 API

3. 需求二：分级调用策略体系

3.1 策略模型设计

3.1.1 三级优先级

3.1.2 每个 AppKey × 每个模...

3.1.3 全局模型并发配置

3.1.4 计费逻辑

3.2 策略执行流程

3.3 策略管理 API

3.3.1 AppKey 策略配置

3.3.2 模型容量配置

3.3.3 实时状态查询

3.4 429 响应格式规范

3.4 初始化建议

<<

模型平台 v1 技术需求文档

1. 背景与目标

1.1 现状

1.2 投产前的核心问题

1.3 目标

1.4 说明

2. 需求一：日志与监控体系

2.1 请求访问日志

2.2 Prometheus 指标

2.2.1 请求指标

2.2.2 Token/用量指标

2.2.3 系统健康指标

2.3 Grafana 仪表盘（需运维配...

2.4 告警规则（需运维配置）

2.5 控制台日志查询 API

3. 需求二：分级调用策略体系

3.1 策略模型设计

3.1.1 三级优先级

3.1.2 每个 AppKey × 每个模...

3.1.3 全局模型并发配置

3.1.4 计费逻辑

3.2 策略执行流程

3.3 策略管理 API

3.3.1 AppKey 策略配置

3.3.2 模型容量配置

3.3.3 实时状态查询

3.4 429 响应格式规范

3.4 初始化建议



模型平台 v1 技术需求文档

1. 背景与目标

1.1 现状

1.2 投产前的核心问题

1.3 目标

1.4 说明

2. 需求一：日志与监控体系

2.1 请求访问日志

2.2 Prometheus 指标

2.2.1 请求指标

2.2.2 Token/用量指标

2.2.3 系统健康指标

2.3 Grafana 仪表盘（需运维配...

2.4 告警规则（需运维配置）

2.5 控制台日志查询 API

3. 需求二：分级调用策略体系

3.1 策略模型设计

3.1.1 三级优先级

3.1.2 每个 AppKey × 每个模...

3.1.3 全局模型并发配置

3.1.4 计费逻辑

3.2 策略执行流程

3.3 策略管理 API

3.3.1 AppKey 策略配置

3.3.2 模型容量配置

3.3.3 实时状态查询

3.4 429 响应格式规范

3.4 初始化建议

<<

模型平台 v1 技术需求文档

1. 背景与目标

1.1 现状

1.2 投产前的核心问题

1.3 目标

1.4 说明

2. 需求一：日志与监控体系

2.1 请求访问日志

2.2 Prometheus 指标

2.2.1 请求指标

2.2.2 Token/用量指标

2.2.3 系统健康指标

2.3 Grafana 仪表盘（需运维配...

2.4 告警规则（需运维配置）

2.5 控制台日志查询 API

3. 需求二：分级调用策略体系

3.1 策略模型设计

3.1.1 三级优先级

3.1.2 每个 AppKey × 每个模...

3.1.3 全局模型并发配置

3.1.4 计费逻辑

3.2 策略执行流程

3.3 策略管理 API

3.3.1 AppKey 策略配置

3.3.2 模型容量配置

3.3.3 实时状态查询

3.4 429 响应格式规范

3.4 初始化建议

<<

模型平台 v1 技术需求文档

1. 背景与目标

1.1 现状

1.2 投产前的核心问题

1.3 目标

1.4 说明

2. 需求一：日志与监控体系

2.1 请求访问日志

2.2 Prometheus 指标

2.2.1 请求指标

2.2.2 Token/用量指标

2.2.3 系统健康指标

2.3 Grafana 仪表盘（需运维配...

2.4 告警规则（需运维配置）

2.5 控制台日志查询 API

3. 需求二：分级调用策略体系

3.1 策略模型设计

3.1.1 三级优先级

3.1.2 每个 AppKey × 每个模...

3.1.3 全局模型并发配置

3.1.4 计费逻辑

3.2 策略执行流程

3.3 策略管理 API

3.3.1 AppKey 策略配置

3.3.2 模型容量配置

3.3.3 实时状态查询

3.4 429 响应格式规范

3.4 初始化建议

<<

模型平台 v1 技术需求文档

1. 背景与目标

1.1 现状

1.2 投产前的核心问题

1.3 目标

1.4 说明

2. 需求一：日志与监控体系

2.1 请求访问日志

2.2 Prometheus 指标

2.2.1 请求指标

2.2.2 Token/用量指标

2.2.3 系统健康指标

2.3 Grafana 仪表盘（需运维配...

2.4 告警规则（需运维配置）

2.5 控制台日志查询 API

3. 需求二：分级调用策略体系

3.1 策略模型设计

3.1.1 三级优先级

3.1.2 每个 AppKey × 每个模...

3.1.3 全局模型并发配置

3.1.4 计费逻辑

3.2 策略执行流程

3.3 策略管理 API

3.3.1 AppKey 策略配置

3.3.2 模型容量配置

3.3.3 实时状态查询

3.4 429 响应格式规范

3.4 初始化建议

<<

模型平台 v1 技术需求文档

1. 背景与目标

1.1 现状

1.2 投产前的核心问题

1.3 目标

1.4 说明

2. 需求一：日志与监控体系

2.1 请求访问日志

2.2 Prometheus 指标

2.2.1 请求指标

2.2.2 Token/用量指标

2.2.3 系统健康指标

2.3 Grafana 仪表盘（需运维配...

2.4 告警规则（需运维配置）

2.5 控制台日志查询 API

3. 需求二：分级调用策略体系

3.1 策略模型设计

3.1.1 三级优先级

3.1.2 每个 AppKey × 每个模...

3.1.3 全局模型并发配置

3.1.4 计费逻辑

3.2 策略执行流程

3.3 策略管理 API

3.3.1 AppKey 策略配置

3.3.2 模型容量配置

3.3.3 实时状态查询

3.4 429 响应格式规范

3.4 初始化建议

<<

模型平台 v1 技术需求文档

1. 背景与目标

1.1 现状

1.2 投产前的核心问题

1.3 目标

1.4 说明

2. 需求一：日志与监控体系

2.1 请求访问日志

2.2 Prometheus 指标

2.2.1 请求指标

2.2.2 Token/用量指标

2.2.3 系统健康指标

2.3 Grafana 仪表盘（需运维配...

2.4 告警规则（需运维配置）

2.5 控制台日志查询 API

3. 需求二：分级调用策略体系

3.1 策略模型设计

3.1.1 三级优先级

3.1.2 每个 AppKey × 每个模...

3.1.3 全局模型并发配置

3.1.4 计费逻辑

3.2 策略执行流程

3.3 策略管理 API

3.3.1 AppKey 策略配置

3.3.2 模型容量配置

3.3.3 实时状态查询

3.4 429 响应格式规范

3.4 初始化建议

<<

模型平台 v1 技术需求文档

1. 背景与目标

1.1 现状

1.2 投产前的核心问题

1.3 目标

1.4 说明

2. 需求一：日志与监控体系

2.1 请求访问日志

2.2 Prometheus 指标

2.2.1 请求指标

2.2.2 Token/用量指标

2.2.3 系统健康指标

2.3 Grafana 仪表盘（需运维配...

2.4 告警规则（需运维配置）

2.5 控制台日志查询 API

3. 需求二：分级调用策略体系

3.1 策略模型设计

3.1.1 三级优先级

3.1.2 每个 AppKey × 每个模...

3.1.3 全局模型并发配置

3.1.4 计费逻辑

3.2 策略执行流程

3.3 策略管理 API

3.3.1 AppKey 策略配置

3.3.2 模型容量配置

3.3.3 实时状态查询

3.4 429 响应格式规范

3.4 初始化建议

<<

模型平台 v1 技术需求文档

1. 背景与目标

1.1 现状

1.2 投产前的核心问题

1.3 目标

1.4 说明

2. 需求一：日志与监控体系

2.1 请求访问日志

2.2 Prometheus 指标

2.2.1 请求指标

2.2.2 Token/用量指标

2.2.3 系统健康指标

2.3 Grafana 仪表盘（需运维配...

2.4 告警规则（需运维配置）

2.5 控制台日志查询 API

3. 需求二：分级调用策略体系

3.1 策略模型设计

3.1.1 三级优先级

3.1.2 每个 AppKey × 每个模...

3.1.3 全局模型并发配置

3.1.4 计费逻辑

3.2 策略执行流程

3.3 策略管理 API

3.3.1 AppKey 策略配置

3.3.2 模型容量配置

3.3.3 实时状态查询

3.4 429 响应格式规范

3.4 初始化建议

<<

模型平台 v1 技术需求文档

1. 背景与目标

1.1 现状

1.2 投产前的核心问题

1.3 目标

1.4 说明

2. 需求一：日志与监控体系

2.1 请求访问日志

2.2 Prometheus 指标

2.2.1 请求指标

2.2.2 Token/用量指标

2.2.3 系统健康指标

2.3 Grafana 仪表盘（需运维配...

2.4 告警规则（需运维配置）

2.5 控制台日志查询 API

3. 需求二：分级调用策略体系

3.1 策略模型设计

3.1.1 三级优先级

3.1.2 每个 AppKey × 每个模...

3.1.3 全局模型并发配置

3.1.4 计费逻辑

3.2 策略执行流程

3.3 策略管理 API

3.3.1 AppKey 策略配置

3.3.2 模型容量配置

3.3.3 实时状态查询

3.4 429 响应格式规范

3.4 初始化建议

<<

模型平台 v1 技术需求文档

1. 背景与目标

1.1 现状

1.2 投产前的核心问题

1.3 目标

1.4 说明

2. 需求一：日志与监控体系

2.1 请求访问日志

2.2 Prometheus 指标

2.2.1 请求指标

2.2.2 Token/用量指标

2.2.3 系统健康指标

2.3 Grafana 仪表盘（需运维配...

2.4 告警规则（需运维配置）

2.5 控制台日志查询 API

3. 需求二：分级调用策略体系

3.1 策略模型设计

3.1.1 三级优先级

3.1.2 每个 AppKey × 每个模...

3.1.3 全局模型并发配置

3.1.4 计费逻辑

3.2 策略执行流程

3.3 策略管理 API

3.3.1 AppKey 策略配置

3.3.2 模型容量配置

3.3.3 实时状态查询

3.4 429 响应格式规范

3.4 初始化建议

<<

模型平台 v1 技术需求文档

1. 背景与目标

1.1 现状

1.2 投产前的核心问题

1.3 目标

1.4 说明

2. 需求一：日志与监控体系

2.1 请求访问日志

2.2 Prometheus 指标

2.2.1 请求指标

2.2.2 Token/用量指标

2.2.3 系统健康指标

2.3 Grafana 仪表盘（需运维配...

2.4 告警规则（需运维配置）

2.5 控制台日志查询 API

3. 需求二：分级调用策略体系

3.1 策略模型设计

3.1.1 三级优先级

3.1.2 每个 AppKey × 每个模...

3.1.3 全局模型并发配置

3.1.4 计费逻辑

3.2 策略执行流程

3.3 策略管理 API

3.3.1 AppKey 策略配置

3.3.2 模型容量配置

3.3.3 实时状态查询

3.4 429 响应格式规范

3.4 初始化建议